Roadmap del Proyecto de Feedback con LLM – 7 Fases

Fase 0 – Setup & Alcance

- Definir MVP: entrada = texto de feedback, salida = respuesta generada por LLM.
- Redactar historias de usuario básicas: «Como usuario quiero...».
- Crear repositorio Git y estructura de carpetas (backend, frontend, README...).
- Configurar entorno virtual e instalar dependencias esenciales: flask, streamlit, groq.
- Añadir archivo .env con GROQ_API_KEY y otras variables.

Fase 1 – Backend Flask – Ruta /feedback

- Implementar endpoint POST /feedback que reciba JSON {"texto": "..."}.
- Responder provisionalmente con «Recibido: ».
- Probar localmente con curl o Insomnia.
- Agregar manejo de errores básicos (texto vacío = 400).

Fase 2 – Integrar LLM con Groq

- Instalar cliente Python de Groq: pip install groq.
- Crear función responder_llm(texto) que llame a la API con prompt adecuado.
- Sustituir respuesta fija por la generada por responder_llm.
- Capturar excepciones de la API y responder 503 en caso de fallo.

Fase 3 – Persistencia con SQLite

- Crear base de datos feedback.db y tabla feedback(id, texto, respuesta, fecha).
- Añadir helper guardar(texto, respuesta) para insertar registros.
- Crear endpoint GET /history que devuelva los últimos N registros en JSON.

Fase 4 - Frontend Streamlit

- Construir interfaz sencilla con st.text_area y botón Enviar que llame a /feedback.
- Mostrar la respuesta del asistente y, opcionalmente, el histórico (/history).
- Añadir st.spinner("Generando respuesta...") para mejorar UX.

Fase 5 – Prompt Engineering

- Separar system prompt y plantilla de usuario en variables.
- Experimentar con temperature, max_tokens y few-shot examples.
- Registrar resultados en CSV para iterar sobre la calidad de respuesta.

Fase 6 - Moderación & Validación

- Implementar lista de palabras prohibidas y rechazar feedback ofensivo (400).
- Limitar longitud del texto y establecer timeout de la llamada al LLM.
- Prevenir coste excesivo rechazando entradas repetidas o vacías.

Fase 7 - Deploy & CI/CD

- Crear Dockerfile con backend y frontend en un contenedor.
- Desplegar en Render/Fly.io/Heroku configurando variables de entorno.
- Configurar GitHub Actions para build y despliegue automático en cada push.